

数据科学与工程数学基础

作业提交规范及第 4 次作业

教师：黄定江

助教：陈诺、刘文辉

2022 年 3 月 10 日

作业提交规范

1. 作业提交形式：**练习本或笔记本**（建议统一使用一般的**练习本**即可，不接收以纸张的方式书写的作业）。
2. 作业书写说明：
 - (a) 可以讨论，**禁止抄袭！**
 - (b) 练习本封面至少包含两方面信息：**姓名和学号**
 - (c) 每一次的作业**请另起一页**，并在**第一行标明第几次作业**。例如“第 4 次作业”；
 - (d) 每一题请**标注题号**，无需抄题，直接解答；
 - (e) 题与题之间**请空一行**；
 - (f) 不要求字好，但要求书写整体清晰易读。
3. 作业提交途径：纸质作业交给**学习委员**，由学习委员**按学号顺序**收齐后统一在截止日期前交到**助教实验室**。**单数周**布置的作业交到助教刘文辉处**数学馆西 109**；**双数周**布置的作业交到助教陈诺处**地理馆 353**。
4. 作业评分说明：正常提交作业的按照实际评分记录；逾期补交作业的根据逾期情况在实际评分基础上酌情扣分；**未交作业的当次作业记为 0 分**。

第 4 次作业



提交截至时间：**2022/03/11 本周五 20:00（晚上）**

理论部分 (范数与二次型)

习题 1. 对偶范数常在共轭函数及一些不等式中出现。向量的对偶函数定义为

$$\|z\|_* = \sup \{z^\top x \mid \|x\| \leq 1\}$$

若向量范数 l_p 与 l_q 互为对偶范数, 则 $p, q \in \mathbb{R}^n$ 需满足 $\frac{1}{p} + \frac{1}{q} = 1$ (称 p, q 为 Hölder 共轭)

(I) 试用对偶范数定义及上述性质证明 Hölder 不等式: 对 $p > 1, \frac{1}{p} + \frac{1}{q} = 1$, 以及 $x, y \in \mathbb{R}^n$

$$\sum_{i=1}^n |x_i y_i| \leq \left(\sum_{i=1}^n |x_i|^p \right)^{1/p} \left(\sum_{i=1}^n |y_i|^q \right)^{1/q}$$

解.

$$\|z\|_* = \sup \{z^\top x \mid \|x\| \leq 1\} = \sup_{x \neq 0} \frac{z^\top x}{\|x\|}$$

$$z^\top x \leq \|x\| \|z\|_*$$

由对偶范数性质

$$z^\top x \leq \|x\|_p \|z\|_q$$

其中, $p, q \in \mathbb{R}^n$ 且满足 $\frac{1}{p} + \frac{1}{q} = 1$

将其用元素形式展开得 Hölder 不等式, 证毕

为便于理解, 以 $q = 1, n = 2$ 为例, $\|x\|_1 \leq 1$, 不妨只考虑该图像在第一象限部分,

$$\text{令 } Z = \begin{pmatrix} z_0 \\ z_1 \end{pmatrix}, X = \begin{pmatrix} kx_0 \\ k(1-x_0) \end{pmatrix}, \|x\|_1 = k, 0 \leq x_0 \leq 1, 0 \leq k \leq 1$$

$$\begin{aligned} & z_0 k x_0 + z_1 k (1 - x_0) \\ &= k ((z_0 - z_1) x_0 + z_1) \\ &\leq \begin{cases} k z_1, \text{ when } z_0 - z_1 \leq 0, \text{ let } x_0 = 0 \\ k z_0, \text{ when } z_0 - z_1 > 0, \text{ let } x_0 = 1 \end{cases} \end{aligned}$$

$$= \|x\|_1 \|z\|_\infty$$

更一般地, 由 Hölder 不等式, 当 $q = \frac{p}{p-1}$, 即 $\frac{1}{p} + \frac{1}{q} = 1$ 时, 可得 $z^\top x \leq \|x\|_p \|z\|_q$ 。因此该对偶范数性质可以理解为范数视角下的 Hölder 不等式。

习题 2. 矩阵的范数主要包括三种主要类型: 诱导范数, 元素形式范数和 Schatten 范数。

诱导范数又称矩阵空间上的算子范数 (operator norm), 常用的诱导范数为 p 范数, 定义如下

$$\|A\|_p = \sup_{\|x\|_p \neq 0} \frac{\|Ax\|_p}{\|x\|_p} = \sup_{\|x\|_p = 1} \|Ax\|_p$$

注: 矩阵的诱导范数是由向量范数诱导而来的, 向量中的每个元素诱导为了每个列向量 (基)。

(I) 设 $A = (a_{ij}) \in \mathbb{C}^{m \times n}$, 证明 l 范数为列和范数, 无穷范数为行和范数

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|, \quad \|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

元素形式范数即矩阵按列排成向量，然后采用向量范数的定义得到的矩阵范数，一般称 l_p 范数。

$$l_p : \|A\|_p = \sqrt[p]{\sum_{i,j} |a_{ij}|^p}$$

(2) 试比较 l_1 范数

$$l_1 : \|A\|_1 = \sum_{i,j} |a_{ij}|^1$$

与诱导范数的关系

解. (1)

$$\begin{aligned} A &= (a, \dots, a_n) \\ \|Ax\|_1 &= \left\| \sum_i a_i x_i \right\|_1 \\ &\leq \sum_i \|a_i x_i\|_1 \\ &= \sum_i \|x_i\| \|a_i\|_1 \\ &\leq (\max_i \|a_i\|_1) \left(\sum_i |x_i| \right) \\ &= \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| \|x\|_1 \\ \|Ax\|_\infty &= \max_i \left| \sum_j a_{ij} x_j \right| \\ &\left| \sum_j a_{ij} x_j \right| \leq \sum_j |a_{ij} x_j| \\ &\leq \sum_j |a_{ij}| \max_j |x_j| \\ \|Ax\|_\infty &\leq \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}| \|x\|_\infty \end{aligned}$$

(2) 以 l_1 范数与 l_∞ 范数，无穷范数为例，有

$$\begin{aligned} \|X\|_1 &\leq \|X\|_1(l_1) \leq n \|X\|_1 \\ \|X\|_\infty &\leq \|X\|_1(l_1) \leq m \|X\|_\infty \end{aligned}$$

实际上对于有限维空间上的任何两个（以矩阵、向量为例）范数（满足非负性、齐次性、三角不等式），他们之间都是等价 (equivalent) 的。范数的等价性 (equivalence) 定义如下：

定义 0.0.1. 设 $\|\cdot\|_\alpha$ 和 $\|\cdot\|_\beta$ 是 $R^{m \times n}(R^n)$ 上任意两个范数, 如果存在 $\mu_1, \mu_2 > 0$, 使得

$$\mu_1 \|X\|_\alpha \leq \|X\|_\beta \leq \mu_2 \|X\|_\alpha, \quad \forall X \in R^{m \times n}(R^n)$$

则称范数 $\|\cdot\|_\alpha$ 和范数 $\|\cdot\|_\beta$ 是等价的。

证: 1. 利用范数三角不等式的性质可以证明对于任意一个 $F^{m \times n}$ 上的范数 $\|\cdot\|$, 函数 $\varphi: F^{m \times n} \mapsto R, \varphi(X) = \|X\|$ 在 L_1 范数下是连续的。

$\forall X, Y \in F^{m \times n}$,

$$\begin{aligned} |\varphi(X) - \varphi(Y)| &= ||X\| - \|Y\|| \\ &= \left| \sum_{i=1}^n \sum_{j=1}^n x_{ij} E_{ij} - \sum_{i=1}^n \sum_{j=1}^n y_{ij} E_{ij} \right| \\ &= \left\| \sum_{i=1}^n \sum_{j=1}^n (x_{ij} - y_{ij}) E_{ij} \right\| \\ &\leq \sum_{i=1}^n \sum_{j=1}^n \|(x_{ij} - y_{ij}) E_{ij}\| \\ &= \sum_{i=1}^n \sum_{j=1}^n |x_{ij} - y_{ij}| \|E_{ij}\| \\ &\rightarrow 0, X \rightarrow Y \end{aligned}$$

其中, $E_{ij} \in F^{m \times n}$ 表示只有在第 i 行第 j 列的元素为 1, 其他元素都为 0 的矩阵。

因此 $\varphi(X)$ 是连续函数。

2. 故 $\varphi(Y; \alpha) = \|Y\|_\alpha$ 在有界闭集 $S = \{Y \in F^{m \times n} : \|Y\|_1 = 1\}$ 上连续, 又 $\varphi(Y; \alpha)$ 在 S 恒大于零, 因此在 S 内必有最大值 $C_{\max} > 0$, 最小值 $C_{\min} > 0$,

同理可得 $\varphi(Y; \beta) = \|Y\|_\beta$ 在 S 内必有最大值 $D_{\max} > 0$, 最小值 $D_{\min} > 0$ 。

为便于理解, 以 $\alpha = \infty, F^{2 \times 1}$ (向量) 为例,




图 1: $\varphi(Y; \infty)$ 在单位范数球 S 上移动

图中蓝色部分为单位范数球 $S = \{Y \in F^{2 \times 1} : \|Y\|_1 = 1\}$, $\varphi(Y; \infty)$ 在黄色处取到最小值 $C_{\min} =$

$\frac{1}{2}$, 在红色处取到最大值 $C_{\min} = 1$ 。

3. $\forall X \in F^{m \times n}$, 若 $X = \mathbf{0}$, 则命题显然成立。

若 $X \neq \mathbf{0}$, 令 $Y = \frac{X}{\|X\|_1}$, $\|Y\|_1 = 1$, 因此对 $Y \in S$, 有 $\frac{\|X\|_\beta}{\|X\|_\alpha} = \frac{\|Y\|_\beta}{\|Y\|_\alpha} \frac{\|X\|_1}{\|X\|_1} = \frac{\varphi(Y; \alpha)}{\varphi(Y; \beta)} \in \left[\frac{D_{\min}}{C_{\max}}, \frac{D_{\max}}{C_{\min}} \right]$ 。

令 $\mu_1 = \frac{D_{\min}}{C_{\max}}, \mu_2 = \frac{D_{\max}}{C_{\min}}$, 则: $0 < \mu_1 \leq \frac{\|X\|_\beta}{\|X\|_\alpha} \leq \mu_2$

习题 3. (作为阅读材料, 不计入分数)

由 $\|A\|_p = \sup_{\|x\|_p \neq 0} \frac{\|Ax\|_p}{\|x\|_p}$,

矩阵 A 的诱导范数可理解为线性变换 Ax 对向量 x 的最大“拉长倍数”

由 $\|A\|_p = \sup_{\|x\|_p = 1} \|Ax\|_p$,

矩阵 A 的诱导范数也可理解为 x 在单位范数球上运动时 $\|Ax\|_p$ 的最大值

以下情形可便于理解诱导范数




图 2: 诱导范数例 ($p=2$)




图 3: 诱导范数例 ($p=1$)

例: 左图为 $A = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$, $p(A) = 1, p = 2$ 时的情形, 在 $x = (\sqrt{2}/2, \sqrt{2}/2)$ 时 $\|Ax\|_2$ 取到最大值 2

例: 右图绿线为 $A = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$, $p = 1$ 时的情形, 在 $x = (1, 0)$ 时 $\|Ax\|_1$ 取到最大值 2

例: 右图橙线为 $A = \begin{pmatrix} 2 & 0 \\ 1 & 2 \end{pmatrix}$, $p = 1$ 时的情形, 在 $x = (1, 1)$ 时 $\|Ax\|_1$ 取到最大值 3

(I) 试证明

$$\|A\|_2 = \sigma_{\max} = \sqrt{\lambda(A^T A)}$$

, 其中 σ_{\max} 为谱范数, 即矩阵 A 的最大奇异值, $\lambda(A^T A)$ 表示 $A^T A$ 的最大特征值。

证: 即证明对于矩阵 $A_{m \times n}$, 对任意向量 x , 在矩阵 A 的变换 (即 Ax) 后, 其长度不大于 $\sigma_{\max} \|x\|_2$,

即 $\|Ax\|_2 \leq \sigma_{\max} \|x\|_2$ 。

$A^T A$ 是实对称阵, 其特征向量两两正交。不妨令 $B = A^T A$, 特征向量矩阵为 $\lambda = \text{diag}(\lambda_1, \dots, \lambda_n) =$

$\begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{pmatrix}, p_1, \dots, p_n$ 为 B 的一组标准正交特征向量, 则 $P = (p_1, \dots, p_n)$ 为正交矩阵, 故

$$BP = P\lambda \Leftrightarrow B = P\lambda P^{-1} \Leftrightarrow B = P\lambda P^T$$

(称 λ 合同于 B) 假设对一个向量 x , 在矩阵 A 的变换 (即 Ax) 后得到 y , 即满足 $y = Ax$ 。则

$$\|y\|_2^2 = y^T y = (Ax)^T (Ax) = x^T A^T A x = x^T B x = x^T P \lambda P^T x = (P^T x)^T \lambda P^T x$$

对于二次型, 可以看作是一个二次齐次多项式的图形, 而正交矩阵 P 的变换, 可以保证变换图形的形状和大小不变, 仅仅做了位移、旋转或翻转的变换, 类似把物体从一个地方移到另一个地方。(可以想象一个三维坐标系, 在坐标系上的点构成的图形通过一个非正交的基表示, 现坐标系换了一组标准正交基 P , 用这组基变换图形不过是移动 (掰正) 了图形的位置。记 $z = P^T x$, 所以 z 不过是一个与 x 一样的 (同范数的) 向量, 只是换了位置, 而 $\lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ 则进行了掰正位置后的放缩。因而

$$\begin{aligned} |y|^2 &= z^T \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{pmatrix} z = \sum_i \lambda_i z_i^2 \\ &= \sum_i \left(\sqrt{\lambda_i} z_i \right)^2 \leq \sum_i \left(\max_j \left(\sqrt{\lambda_j} \right) z_i \right)^2 \\ &= \max \left(\sqrt{\lambda_j} \right)^2 \sum_i z_i^2 = \max (\lambda_j) |z|^2 = \max (\lambda_j) |x|^2 \end{aligned}$$

当且仅当除 $z_{\text{opt max}_j(\lambda_j)}$ 以外的其他元素均等于 0 时, 该不等式的等号成立。

即 $\|Ax\|_2 \leq \sigma_{\max} \|x\|_2$, 证毕

(2) 元素形式下矩阵的 l_2 范数称为 *Frobenius* 范数, 即

$$l_2 : \|A\|_F = \sqrt{\sum_{i,j} |a_{ij}|^2}$$

试比较 $\|A\|_2$ 与 $\|A\|_F$ 的大小

答: $\|A\|_2 \leq \|A\|_F$

习题 4. 上题提到矩阵 A 的诱导范数也可理解为 x 在单位范数球上运动时 $\|Ax\|_p$ 的最大值, 而对于某些矩阵, x 的巨大变化只能引起 Ax 很小的变化 (旋转而非放缩)。反之, 对于线性方程组 $Ax = b$, b (或 A) 的微小变化会带来解 x 的巨大变化。这样的矩阵 A (及线性方程组) 称作病态的。如 $A = \begin{pmatrix} 1 & 1 \\ 1 & 1.0001 \end{pmatrix}$

$$\begin{pmatrix} 1 & 1 \\ 1 & 1.0001 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \end{pmatrix} \Rightarrow \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 0 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 1 \\ 1 & 1.0001 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 2.0001 \end{pmatrix} \Rightarrow \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$\|\delta b\|_\infty = \|(2, 2)^T - (2, 2.0001)^T\|_\infty = 0.0001$, $\|\delta x\|_\infty = \|(2, 0)^T - (1, 1)^T\|_\infty = 1$, 方程组解 x 的变化程度是 b 变化程度的 10000 倍, 因此称矩阵 A 是病态的。

(1) 试推测什么样的矩阵是病态矩阵, 用矩阵范数表示。

提示: 对线性方程组 $Ax = b$, 设 A 是精确的, b 有微小的扰动 δb , 新方程组的解为 $x + \delta x$, 即 $A(x + \delta x) = b + \delta b$, 用

$$Ax = b \Rightarrow \|A\| \|x\| \geq \|b\|$$

$$A\delta x = \delta b, \delta x = A^{-1}\delta b \Rightarrow \|\delta x\| = \|A^{-1}\delta b\| \leq \|A^{-1}\| \|\delta b\|$$

证明

$$\frac{\|\delta x\|}{\|x\|} \leq \|A^{-1}\| \|A\| \frac{\|\delta b\|}{\|b\|}$$

解. 对于提示中的证明, 将两个不等式相乘即可, 故评价矩阵输入误差的敏感性指标为 $k(A) = \|A\| \cdot \|A^{-1}\|$ (又称条件数)。

以二维向量为例, $A = (a_1, a_2)$ 对 x 的变换 Ax 相当于把 x 从 $(1, 0), (0, 1)$ 的基换成了 a_1, a_2 的基下表示, 而这个变换又可以拆分为旋转, 放缩和投影三种效应 (通过之后会学到的奇异值分解)。

对于 $A = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$ 这样的奇异阵, 由于基 $(1, 1)$ 与 $(1, 1)$ 方向相同, 所以 Ax 只能在一个方向移动 (没有旋转), 同时也可注意到最小特征值为 0 (由于 A 是对称方阵, 特征向量两两正交, 故特征值与奇异值相等)。

$A' = \begin{pmatrix} 1 & 1 \\ 1 & 1.0001 \end{pmatrix}$ 只是在上述共线的基上进行很小的变换, 所以基的夹角很小, 即使 x 变化很大, 也只能引起 Ax 很小的变化。同时也可注意到, 最小特征值从 0 变为约 0.00005。

实际上, 在二范数下, 条件数等于最大奇异值与最小奇异值的比。

$$\|A\|_2 = \sigma_{\max}(A)$$

$$\|A^{-1}\|_2 = \sigma_{\max}(A^{-1}) = 1/\sigma_{\min}(A)$$

$$k(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}$$

其中, $\sigma_{\max}(A)$ 为矩阵 A 的最大奇异值, $\sigma_{\min}(A)$ 为矩阵 A 的最小奇异值。

特殊地, 对于对称方阵, 特征值与奇异值相等, 条件数又可表示为

$$k(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}$$

其中, $\lambda_{\max}(A)$ 为矩阵 A 的最大特征值, $\lambda_{\min}(A)$ 为矩阵 A 的最小特征值。